در این فصل می‌کوشیم فاصله‌ای کوتاه به جلو را ببینیم.

در فصل ۲، تصمیم گرفتیم هوش مصنوعی را به‌عنوانِ تکلیفِ طراحیِ عامل‌های تقریباً عقلایی ببینیم. انواعِ گوناگونی از طراحی‌های عامل در نظر گرفته شد، از عامل‌های بازتابی تا عامل‌های دانش‌محورِ تصمیم‌نظری تا عامل‌های یادگیریِ عمیقِ استفاده‌کننده از یادگیریِ تقویتی. همچنین در فناوری‌های مؤلفه‌ای که این طراحی‌ها از آن‌ها مونتاژ می‌شوند تنوع هست: استدلالِ منطقی، احتمالاتی یا عصبی؛ بازنمایی‌های اتمی، عامل‌بندی‌شده یا ساخت‌یافتهٔ حالت‌ها؛ الگوریتم‌های یادگیریِ گوناگون از انواعِ گوناگونِ داده؛ حس‌گذارها و عملگرها برای تعامل با جهان. سرانجام، انواعِ گوناگونی از کاربردها دیده‌ایم، در پزشکی، مالی، حمل‌ونقل، ارتباطات و دیگر حوزه‌ها. در همهٔ این جبهه‌ها پیشرفت بوده، هم در فهمِ علمیِ ما و هم در قابلیت‌های فناورانه‌مان.

بیشترِ کارشناسان دربارهٔ پیشرفتِ ادامه‌دار خوش‌بین‌اند؛ چنان‌که در صفحهٔ ۲۸ دیدیم، برآوردِ میانه برای هوش مصنوعیِ تقریباً سطح-انسان در طیفِ وسیعی از تکلیف‌ها جایی در ۵۰ تا ۱۰۰ سالِ آینده است. در دههٔ آینده، پیش‌بینی می‌شود هوش مصنوعی هر سال تریلیون‌ها دلار به اقتصاد بیفزاید. اما چنان‌که همچنین دیدیم، منتقدانی هستند که فکر می‌کنند هوش مصنوعیِ عمومی قرن‌ها فاصله دارد، و نگرانی‌های اخلاقیِ متعددی دربارهٔ انصاف، برابری و کشندگیِ هوش مصنوعی هست. در این فصل، می‌پرسیم: به کجا می‌رویم و چه کاری باقی مانده؟ این کار را با پرسیدنِ اینکه آیا مؤلفه‌ها، معماری‌ها و هدف‌های درستی داریم تا هوش مصنوعی را به فناوریِ موفقِ سودرساننده به جهان تبدیل کنیم انجام می‌دهیم.

۲۸.۱ مؤلفه‌های هوش مصنوعی

این بخش مؤلفه‌های سامانه‌های هوش مصنوعی و میزانی را بررسی می‌کند که هر یک از آن‌ها ممکن است پیشرفتِ آینده را شتاب یا کند کند.

حس‌گذارها و عملگرها

برای بخشِ بزرگی از تاریخِ هوش مصنوعی، دسترسیِ مستقیم به جهان به‌شکلِ آشکاری غایب بود. با چند استثنای قابلِ توجه، سامانه‌های هوش مصنوعی چنان ساخته می‌شدند که انسان‌ها باید ورودی‌ها را تأمین و خروجی‌ها را تفسیر می‌کردند. در این میان، سامانه‌های رباتیک بر تکلیف‌های سطح‌پایینی تمرکز می‌کردند که استدلال و برنامه‌ریزیِ سطح‌بالا در آن‌ها تا حدِ زیادی نادیده گرفته می‌شد و نیاز به ادراک کمینه می‌شد. این تا حدی به‌دلیلِ هزینهٔ زیاد و تلاشِ مهندسیِ لازم برای اینکه ربات‌های واقعی اصلاً کار کنند بود، و تا حدی به‌دلیلِ فقدانِ قدرتِ پردازشِ کافی و الگوریتم‌های به‌اندازهٔ کافی مؤثر برای مدیریتِ ورودیِ بصریِ پهن‌باندِ بالا.

اوضاع در سال‌های اخیر با در دسترس‌بودنِ ربات‌های برنامه‌پذیرِ آماده به‌سرعت تغییر کرده. این‌ها، به‌نوبهٔ خود، از درایوهای موتورِ فشردهٔ قابلِ‌اعتماد و حس‌گذارهای بهبودیافته بهره برده‌اند. هزینهٔ لیدار برای خودرویِ خودران از ۷۵٬۰۰۰ دلار به ۱٬۰۰۰ دلار سقوط کرده، و نسخهٔ تک‌تراشه‌ای ممکن است به ۱۰ دلار به‌ازایِ هر واحد برسد (پولتون و واتس، 2016). حس‌گذارهای رادار، که زمانی فقط قادر به تشخیصِ درشت‌دانه بودند، اکنون به‌اندازهٔ کافی حساس‌اند که تعدادِ ورق‌های یک دسته کاغذ را بشمارند (یئو و همکاران، 2018).

تقاضا برای پردازشِ تصویرِ بهتر در دوربین‌های گوشیِ همراه، دوربین‌های باکیفیتِ ارزانی برای استفاده در رباتیک به ما داده. فناوریِ MEMS (سامانه‌های میکرو-الکترومکانیکی) شتاب‌سنج‌ها، ژیروسکوپ‌ها و عملگرهای ریزپردازی‌شده‌ای فراهم کرده که به‌اندازهٔ کافی کوچک‌اند تا در حشراتِ مصنوعیِ پرنده جا شوند (فلوریانو و همکاران، 2009؛ فولر و همکاران، 2014). ممکن است بتوان میلیون‌ها دستگاهِ MEMS را برای تولیدِ

عملگرهای ماکروسکوپیِ قدرتمند ترکیب کرد. چاپِ سه‌بعدی (موث و همکاران، 2014) و چاپِ زیستی (کولسکی و همکاران، 2014) آزمایش با نمونه‌های اولیه را آسان‌تر کرده‌اند.

پس، می‌بینیم سامانه‌های هوش مصنوعی در آستانهٔ حرکت از سامانه‌های عمدتاً فقط-نرم‌افزاری به سامانه‌های رباتیکِ جاسازی‌شدهٔ مفیدند. وضعیتِ رباتیکِ امروز تقریباً قابلِ مقایسه با وضعیتِ رایانه‌های شخصی در اوایلِ دههٔ ۱۹۸۰ است: در آن زمان رایانه‌های شخصی در حالِ در دسترس‌شدن بودند، اما یک دههٔ دیگر طول می‌کشید تا رایج شوند. محتمل است ربات‌های منعطف و هوشمند نخست در صنعت گام‌های بلند بردارند (جایی که محیط‌ها کنترل‌شده‌ترند، تکلیف‌ها تکراری‌ترند، و ارزشِ سرمایه‌گذاری آسان‌تر اندازه‌گیری می‌شود) پیش از بازارِ خانگی (جایی که تغییرپذیریِ بیشتری در محیط و تکلیف‌ها هست).

بازنماییِ حالتِ جهان

پیگیریِ جهان مستلزمِ ادراک و همچنین به‌روزرسانیِ بازنمایی‌های درونی است. فصل ۴ نشان داد چگونه بازنمایی‌های حالتِ اتمی را پیگیری کنیم؛ فصل ۷ توصیف کرد چگونه آن را برای بازنمایی‌های حالتِ عامل‌بندی‌شده (گزاره‌ای) انجام دهیم؛ فصل ۱۰ این را به منطقِ مرتبهٔ اول بسط داد؛ و فصل ۱۴ استدلالِ احتمالاتی را در طولِ زمان در محیط‌های نامطمئن توصیف کرد. فصل ۲۱ شبکه‌های عصبیِ بازگشتی را معرفی کرد، که همچنین قادر به نگه‌داشتنِ بازنماییِ حالت در طولِ زمان‌اند.

الگوریتم‌های فیلترکردن و ادراکِ کنونی را می‌توان ترکیب کرد تا کارِ معقولی در بازشناسیِ اشیا («آن گربه است») و گزارشِ گزاره‌های سطح‌پایین («فنجان رویِ میز است») انجام دهد. بازشناسیِ کنش‌های سطح‌بالاتر، مانندِ «دکتر راسل با دکتر نورویگ در حالِ نوشیدنِ چای است و دربارهٔ برنامه‌های هفتهٔ آینده بحث می‌کند»، دشوارتر است. در حالِ حاضر، گاهی می‌توان آن را انجام داد (شکل ۲۵.۱۷ در صفحهٔ ۹۰۸ را ببینید) با توجه به مثال‌های آموزشیِ کافی، اما پیشرفتِ آینده به فنونی نیاز خواهد داشت که بدونِ نیاز به مثال‌های جامع به موقعیت‌های تازه تعمیم می‌کنند (پوپه، 2010؛ کانگ و وایلز، 2016).

مشکلِ دیگر این است که هرچند الگوریتم‌های فیلترکردنِ تقریبیِ فصل ۱۴ می‌توانند محیط‌های نسبتاً بزرگ را مدیریت کنند، آن‌ها همچنان با بازنماییِ عامل‌بندی‌شده سروکار دارند—متغیرهای تصادفی دارند، اما اشیا و رابطه‌ها را به‌صورتِ صریح بازنمایی نمی‌کنند. همچنین، مفهومِ زمانِ آن‌ها به تغییرِ گام‌به‌گام محدود است؛ با توجه به مسیرِ اخیرِ توپ، می‌توانیم پیش‌بینی کنیم در زمانِ $t+1$ کجا خواهد بود، اما بازنماییِ ایدهٔ انتزاعیِ «هرچه بالا رود پایین می‌آید» دشوار است. بخش ۱۵.۱ توضیح داد چگونه احتمال و منطقِ مرتبهٔ اول را می‌توان برای حلِ این مسائل ترکیب کرد؛ بخش ۱۵.۲ نشان داد چگونه با عدم‌قطعیت دربارهٔ هویتِ اشیا سروکار کنیم؛ و فصل ۲۵ نشان داد چگونه شبکه‌های عصبیِ بازگشتی بینناییِ رایانه را قادر به ردیابیِ جهان می‌کنند؛ اما هنوز راهِ خوبی برای کنارِ هم گذاشتنِ همهٔ این فنون نداریم.

فصل ۲۴ نشان داد چگونه جاسازیِ واژه و بازنمایی‌های مشابه می‌توانند ما را از مرزهای سختِ مفاهیمِ تعریف‌شده با شرایطِ لازم و کافی رها کنند. تعریفِ طرح‌های بازنماییِ عمومی و قابلِ استفادهٔ مجدد برای حوزه‌های پیچیده همچنان تکلیفی دلهره‌آور است.

انتخابِ کنش‌ها

دشواریِ اصلی در انتخابِ کنش در جهانِ واقعی کنارآمدن با «برنامه‌های بلندمدت»—مانندِ فارغ‌التحصیل‌شدن از کالج در چهار سال—است که شاملِ میلیاردها گامِ ابتدایی‌اند.

الگوریتم‌های جستجویی که دنباله‌های کنشِ ابتدایی را در نظر می‌گیرند فقط تا ده‌ها یا شاید صدها گام مقیاس می‌شوند. فقط با تحمیلِ ساختارِ سلسله‌مراتبی بر رفتار است که ما انسان‌ها اصلاً کنار می‌آییم. در بخش ۱۱.۴ دیدیم چگونه از بازنمایی‌های سلسله‌مراتبی برای مدیریتِ مسائلِ این مقیاس استفاده کنیم؛ افزون بر این، کار در یادگیریِ تقویتیِ سلسله‌مراتبی در ترکیبِ این ایده‌ها با فرمالیسمِ MDP◌ توصیف‌شده در فصل ۱۷ موفق بوده.

در حالِ حاضر، این روش‌ها به حالتِ با مشاهدهٔ جزئی (POMDPها) بسط نیافته‌اند. افزون بر این، الگوریتم‌های حلِ POMDP معمولاً از همان بازنماییِ حالتِ اتمیِ استفاده‌شده برای الگوریتم‌های جستجویِ فصل ۳ استفاده می‌کنند. به‌وضوح کارِ زیادی

این‌جا برای انجام هست، اما بنیان‌های فنی تا حدِ زیادی برای پیشرفت فراهم‌اند. عنصرِ گمشدهٔ اصلی روشی مؤثر برای ساختِ بازنمایی‌های سلسله‌مراتبیِ حالت و رفتار است که برای تصمیم‌گیری در بازه‌های زمانیِ بلند لازم‌اند.

تصمیم‌گیری دربارهٔ آنچه می‌خواهیم

فصل ۳ الگوریتم‌های جستجو را برای یافتنِ حالتِ هدف معرفی کرد. اما عامل‌های هدف‌محور وقتی محیط نامطمئن است و عواملِ متعددی برای درنظرگرفتن هست شکننده‌اند. در اصل، عامل‌های بیشینه‌کنندهٔ مطلوبیت آن مسائل را به‌شیوه‌ای کاملاً کلی بررسی می‌کنند. حوزه‌های اقتصاد و نظریهٔ بازی، و همچنین هوش مصنوعی، از این بینش استفاده می‌کنند: فقط اعلام کن می‌خواهی چه چیزی را بهینه کنی و هر کنش چه می‌کند، و می‌توانیم کنشِ بهینه را محاسبه کنیم.

در عمل، با این حال، اکنون می‌فهمیم تکلیفِ انتخابِ تابعِ مطلوبیتِ درست به‌خودیِ‌خود مسئلهٔ چالش‌برانگیزی است. برای نمونه، شبکهٔ پیچیدهٔ ترجیح‌های متعامل را تصور کن که عاملی که به‌عنوانِ دستیارِ اداری برای انسان عمل می‌کند باید بفهمد. مسئله با این واقعیت تشدید می‌شود که هر انسان متفاوت است، پس عاملی که تازه «خارج از جعبه» آمده تجربهٔ کافی با هیچ فردِ تکی‌ای برای یادگیریِ مدلِ ترجیحِ دقیق نخواهد داشت؛ لزوماً باید تحتِ عدمِ‌قطعیتِ ترجیح عمل کند. پیچیدگیِ بیشتر اگر بخواهیم مطمئن شویم عامل‌هایمان به‌گونه‌ای عمل می‌کنند که برای جامعه منصفانه و عادلانه است، نه فقط برای فردِ تکی، پیش می‌آید.

هنوز تجربهٔ چندانی در ساختنِ مدل‌های ترجیحِ پیچیدهٔ جهانِ واقعی نداریم، چه رسد به توزیع‌های احتمالِ رویِ چنین مدل‌هایی. هرچند فرمالیسم‌های عامل‌بندی‌شده‌ای، شبیهِ شبکه‌های بیزی، هست که برای تجزیهٔ ترجیح‌ها رویِ حالت‌های پیچیده در نظر گرفته شده‌اند، استفاده از این فرمالیسم‌ها در عمل دشوار ثابت شده. یک دلیل ممکن است این باشد که ترجیح‌ها رویِ حالت‌ها واقعاً از ترجیح‌ها رویِ تاریخچه‌های حالت، که توسط توابعِ پاداش توصیف می‌شوند (فصل ۱۷ را ببینید)، کامپایل می‌شوند. حتی اگر تابعِ پاداش ساده باشد، تابعِ مطلوبیتِ متناظر ممکن است بسیار پیچیده باشد.

این پیشنهاد می‌کند تکلیفِ «مهندسیِ دانش برای توابعِ پاداش» را جدی بگیریم، به‌عنوانِ راهی برای انتقالِ آنچه می‌خواهیم عامل‌هایمان انجام دهند. ایدهٔ یادگیریِ تقویتیِ معکوس (بخش ۲۲.۶) یک رویکرد به این مسئله است وقتی کارشناسی داریم که می‌تواند تکلیفی را انجام دهد، اما نه آن را تبیین کند. همچنین می‌توانستیم از زبان‌های بهتری برای بیانِ آنچه می‌خواهیم استفاده کنیم. برای نمونه، در رباتیک، «منطقِ زمانیِ خطی» گفتنِ اینکه چه چیزهایی می‌خواهیم در آیندهٔ نزدیک رخ دهند، از چه چیزهایی می‌خواهیم اجتناب کنیم، و چه حالت‌هایی می‌خواهیم برای همیشه ادامه یابند را آسان‌تر می‌کند (لیتمن و همکاران، 2017). به راه‌های بهتری برای گفتنِ آنچه می‌خواهیم و راه‌های بهتری برای تفسیرِ خواسته‌هایمان توسط ربات‌ها نیاز داریم.

صنعتِ رایانه به‌عنوانِ کل اکوسیستمِ قدرتمندی برای تجمیعِ ترجیح‌های کاربر توسعه داده. وقتی رویِ چیزی در برنامه‌ای، بازیِ برخط، شبکهٔ اجتماعی یا سایتِ خرید کلیک می‌کنید، آن به‌عنوانِ توصیه‌ای خدمت می‌کند که شما (و هم‌تایانِ مشابه‌تان) دوست دارید در آینده چیزهای مشابهی ببینید. (یا شاید سایت گیج‌کننده است و رویِ چیزِ اشتباهی کلیک کرده‌اید—داده همیشه نویزی است.) بازخوردِ نهفته در این سامانه آن را در کوتاه‌مدت برای برگزیدنِ بازی‌ها و ویدئوهای روزبه‌روز اعتیادآورتر بسیار مؤثر می‌کند.

اما این سامانه‌ها اغلب در فراهم‌کردنِ راهی آسان برای انصراف ناکام‌اند—دستگاهِ شما ویدئویِ مرتبطی را خودکار پخش می‌کند، اما احتمالِ کمتری دارد به شما بگوید «شاید وقتش است دستگاه‌ها را کنار بگذاری و قدمی آرام‌بخش در طبیعت بزنی.» سایتِ خرید به شما کمک می‌کند لباس‌هایی بیابید که با سبکِ شما می‌خواند، اما به صلحِ جهانی یا پایانِ گرسنگی و فقر نخواهد پرداخت. تا جایی که منویِ انتخاب‌ها توسط شرکت‌هایی رانده می‌شود که می‌خواهند از توجهِ مشتری سود ببرند، منو ناقص باقی خواهد ماند. با این حال، شرکت‌ها به علایقِ مشتریان پاسخ می‌دهند، و بسیاری از مشتریان این نظر را ابراز کرده‌اند که به جهانی منصفانه و پایدار علاقه‌مندند. تیم اوریلی دلیل اینکه سود تنها انگیزه نیست را با قیاسِ زیر تبیین می‌کند: «پول مانندِ بنزین در سفرِ جاده‌ای است. نمی‌خواهی در سفرت بنزینت تمام شود، اما تورِ پمپ‌بنزین‌ها هم نمی‌روی. باید به پول توجه کنی، اما نباید دربارهٔ پول باشد.»

جنبشِ «زمانِ خوب‌گذرانده»ی تریستان هریس در مرکزِ فناوریِ انسانی گامی به سمتِ دادنِ انتخاب‌های کامل‌تر به ماست (هریس، 2016). این جنبش به مسئله‌ای می‌پردازد که هربرت سایمون در 1971 بازشناسی کرد: «ثروتِ اطلاعات فقرِ توجه ایجاد می‌کند.» شاید در آینده «عاملِ شخصی»ی (Personal Agent) داشته باشیم که از منافعِ واقعیِ بلندمدتِ ما دفاع می‌کند، نه منافعِ شرکت‌هایی که برنامه‌هایشان اکنون دستگاه‌های ما را پر کرده. کارِ عامل میانجی‌گریِ پیشنهادهای فروشنده‌های گوناگون، محافظت از ما در برابرِ جلب‌کننده‌های توجهِ اعتیادآور، و هدایتِ ما به سمتِ هدف‌هایی خواهد بود که واقعاً برایمان مهم‌اند.

یادگیری

فصل‌های ۱۹ تا ۲۲ توصیف کردند چگونه عامل‌ها می‌توانند یاد بگیرند. الگوریتم‌های کنونی می‌توانند با مسائلِ نسبتاً بزرگ کنار بیایند و در بسیاری از تکلیف‌ها به قابلیت‌های انسانی برسند یا از آن فراتر روند—تا زمانی که مثال‌های آموزشیِ کافی داشته باشیم و با واژگانِ ازپیش‌تعریف‌شده‌ای از ویژگی‌ها و مفاهیم سروکار داشته باشیم. اما یادگیری وقتی داده تنک است، یا نظارت‌نشده است، یا با بازنمایی‌های پیچیده سروکار داریم، می‌تواند متوقف شود. بخشِ زیادی از احیایِ اخیرِ هوش مصنوعی در مطبوعاتِ عمومی و صنعت به‌دلیلِ موفقیتِ یادگیری عمیق (فصل ۲۱) است. از یک سو، می‌توان این را بلوغِ تدریجیِ زیرحوزهٔ شبکه‌های عصبی دید. از سوی دیگر، می‌توانیم آن را جهشی انقلابی در قابلیت‌ها ببینیم که توسط هم‌گراییِ عوامل زیر برانگیخته شده: در دسترس‌بودنِ دادهٔ آموزشیِ بیشتر به‌لطفِ اینترنت، قدرتِ پردازشِ افزایش‌یافته از سخت‌افزارِ تخصصی، و چند ترفندِ الگوریتمی، مانندِ شبکه‌های مولدِ تخاصمی (GAN)، نرمال‌سازیِ دسته‌ای، دراپ‌اوت و تابعِ فعال‌سازیِ خطیِ تصحیح‌شده (ReLU).

آینده باید تأکیدِ ادامه‌دار بر بهبودِ یادگیری عمیق برای تکلیف‌هایی که در آن‌ها عالی است، و همچنین بسطِ آن برای پوششِ تکلیف‌های دیگر ببیند. نامِ تجاریِ «یادگیری عمیق» چنان محبوب ثابت شده که باید انتظارِ ادامهٔ استفاده‌اش را داشته باشیم، حتی اگر ترکیبِ فنونی که آن را تغذیه می‌کنند به‌شکلِ چشمگیری تغییر کند.

ظهورِ حوزهٔ «علمِ داده» را به‌عنوانِ هم‌گراییِ آمار، برنامه‌نویسی و تخصصِ حوزه دیده‌ایم. در حالی که می‌توانیم انتظارِ توسعهٔ ادامه‌دارِ ابزارها و فنونِ لازم برای کسب، مدیریت و نگه‌داریِ دادهٔ بزرگ را داشته باشیم، همچنین به پیشرفت‌هایی در یادگیریِ انتقالی نیاز خواهیم داشت تا بتوانیم از دادهٔ یک حوزه برای بهبودِ عملکرد در حوزهٔ مرتبط بهره بگیریم.

اکثریتِ قریبِ به‌اتفاقِ پژوهشِ یادگیریِ ماشینیِ امروز بازنماییِ عامل‌بندی‌شده را فرض می‌کند، و تابعِ $h : \mathbb{R}^n \to \mathbb{R}$ برای رگرسیون و $h : \mathbb{R}^n \to \{0,1\}$ برای رده‌بندی یاد می‌گیرد. یادگیریِ ماشینی برای مسائلی که فقط مقدارِ کمی داده دارند، یا مسائلی که مستلزمِ ساختِ بازنمایی‌های ساخت‌یافته، سلسله‌مراتبیِ تازه‌اند، موفقیتِ کمتری داشته. یادگیری عمیق، به‌ویژه با شبکه‌های پیچشیِ اعمال‌شده بر مسائلِ بینایيِ رایانه، موفقیتی در رفتن از پیکسل‌های سطح‌پایین به مفاهیمِ سطحِ میانی مانندِ چشم و دهان، سپس چهره، و سرانجام شخص یا گربه نشان داده.

چالشی برای آینده ترکیبِ روان‌ترِ یادگیری و دانشِ قبلی است. اگر مسئله‌ای به رایانه بدهیم که قبلاً با آن روبه‌رو نشده—مثلاً، بازشناسیِ مدل‌های متفاوتِ خودرو—نمی‌خواهیم سامانه تا وقتی میلیون‌ها مثالِ برچسب‌خورده تغذیه نشده ناتوان باشد. سامانهٔ ایده‌آل باید بتواند بر آنچه از قبل می‌داند تکیه کند: باید از قبل مدلی از اینکه بینایی چگونه کار می‌کند، و طراحی و برندسازیِ محصولات به‌طورِ کلی چگونه کار می‌کند داشته باشد؛ حالا باید از یادگیریِ انتقالی برای اعمالِ آن بر مسئلهٔ تازهٔ مدل‌های خودرو استفاده کند. باید بتواند به‌تنهایی اطلاعاتی دربارهٔ مدل‌های خودرو بیابد، از متن، تصاویر و ویدئویِ موجود در اینترنت. باید قادر به یادگیریِ کارآموزی باشد: گفتگویی با معلم داشته باشد، و نه فقط «می‌شود هزار تصویر از کورولا داشته باشم» بپرسد، بلکه بتواند توصیه‌ای مانندِ «این سایت شبیهِ پریوس است، اما سایت جلوپنجرهٔ بزرگ‌تری دارد» را بفهمد. باید بداند هر مدل در دامنهٔ کوچکی از رنگ‌های ممکن می‌آید، اما خودرو را می‌توان دوباره رنگ کرد، پس شانسی هست خودرویی در رنگی ببیند که در مجموعهٔ آموزشی نبود. (اگر آن را نمی‌دانست، باید قادر به یادگیریِ آن، یا شنیدنِ آن، باشد.) همهٔ این‌ها به زبانِ ارتباط و بازنماییِ مشترکِ انسان‌ها و رایانه‌ها نیاز دارد؛ نمی‌توانیم انتظار داشته باشیم تحلیلگرِ انسانی مستقیماً مدلی با میلیون‌ها وزن را اصلاح کند. مدل‌های

احتمالاتی (از جملهِ زبان‌های برنامه‌نویسیِ احتمالاتی) به انسان‌ها توانایی توصیفِ آنچه می‌دانند می‌دهند، اما این مدل‌ها هنوز با دیگر سازوکارهای یادگیری خوب یکپارچه نشده‌اند. کارِ بنجیو و لکون (2007) گامی به سمتِ این یکپارچگی است. اخیراً یان لکون پیشنهاد کرده اصطلاحِ «یادگیری عمیق» باید با «برنامه‌نویسیِ مشتق‌پذیر»ی (Differentiable Programming) عمومی‌تر جایگزین شود (سیسکیند و پرلموتر، 2016؛ لی و همکاران، 2018)؛ این پیشنهاد می‌کند زبان‌های برنامه‌نویسیِ عمومیِ ما و مدل‌های یادگیریِ ماشینیِ ما می‌توانند ادغام شوند. در حالِ حاضر، ساختنِ مدلِ یادگیریِ عمیقی که مشتق‌پذیر است، و بنابراین می‌تواند برای کمینه‌کردنِ زیان آموزش ببیند و وقتی شرایط تغییر می‌کند بازآموزی شود، رایج است. اما آن مدلِ یادگیریِ عمیق فقط بخشی از سامانهٔ نرم‌افزاریِ بزرگ‌تری است که داده می‌گیرد، داده را ور می‌دهد، به مدل می‌خوراند، و می‌فهمد با خروجیِ مدل چه کند. همهٔ این بخش‌های دیگرِ سامانهٔ بزرگ‌تر توسط برنامه‌نویسی با دست نوشته شده‌اند، و بنابراین غیرمشتق‌پذیرند، که به این معناست وقتی شرایط تغییر می‌کند، این به عهدهٔ برنامه‌نویس است مشکلات را تشخیص دهد و با دست رفع کند. با برنامه‌نویسیِ مشتق‌پذیر، امید این است کلِ سامانه تابعِ بهینه‌سازیِ خودکار باشد.

هدفِ نهایی این است بتوانیم آنچه می‌دانیم را به هر شکلی که برایمان راحت است بیان کنیم: توصیهٔ غیررسمی که به زبانِ طبیعی داده می‌شود، قانونِ ریاضیِ قوی مانندِ $F = ma$ ، مدلِ آماریِ همراه با داده، یا برنامهٔ احتمالاتی با پارامترهای ناشناخته که می‌تواند از طریقِ نزولِ گرادیان به‌صورتِ خودکار بهینه شود. مدل‌های رایانه‌ایِ ما از گفتگو با کارشناسانِ انسانی و همچنین با استفاده از همهٔ دادهٔ در دسترس یاد خواهند گرفت.

یان لکون، جفری هینتون و دیگران پیشنهاد کرده‌اند تأکیدِ کنونی بر یادگیریِ نظارت‌شده (و تا حدی کمتر، یادگیریِ تقویتی) پایدار نیست—مدل‌های رایانه‌ای باید به «یادگیریِ ضعیف‌نظارت» تکیه کنند، که در آن نظارتی با تعدادِ کمی مثالِ برچسب‌خورده و/یا تعدادِ کمی پاداش داده می‌شود، اما بیشترِ یادگیری نظارت‌نشده است، زیرا دادهٔ بدونِ حاشیه‌نویسی بسیار فراوان‌تر است.

لکون از اصطلاحِ «یادگیریِ پیش‌بینانه» (Predictive Learning) برای سامانهٔ یادگیریِ نظارت‌نشده‌ای استفاده می‌کند که می‌تواند جهان را مدل کند و یاد بگیرد جنبه‌هایی از حالت‌های آیندهٔ جهان را پیش‌بینی کند—نه فقط برچسب‌هایی برای ورودی‌های مستقل و هم‌توزیع با دادهٔ گذشته پیش‌بینی کند، و نه فقط تابعِ ارزشی رویِ حالت‌ها. پیشنهاد می‌کند GAN ها (شبکه‌های مولدِ تخاصمی) را می‌توان برای یادگیریِ کمینه‌کردنِ تفاوتِ بینِ پیش‌بینی‌ها و واقعیت استفاده کرد.

جفری هینتون در 2017 گفت «دیدگاهِ من این است همه‌چیز را دور بریز و از نو شروع کن»، یعنی ایدهٔ کلیِ یادگیری با تنظیمِ پارامترها در شبکه ماندگار است، اما جزئیاتِ معماریِ شبکه‌ها و فنِ پسانتشار باید بازاندیشی شود. اسمولنسکی (1988) نسخه‌ای برای نحوهٔ اندیشیدن دربارهٔ مدل‌های پیوندگرا داشت؛ اندیشه‌هایش امروز همچنان مرتبط‌اند.

منابع

پژوهش و توسعهٔ یادگیریِ ماشینی با افزایشِ در دسترس‌بودنِ داده، ذخیره، قدرتِ پردازش، نرم‌افزار، کارشناسانِ آموزش‌دیده و سرمایه‌گذاری‌های لازم برای پشتیبانی از آن‌ها شتاب گرفته. از دههٔ ۱۹۷۰، ۱۰۰٬۰۰۰ برابر سرعت‌بخشی در پردازنده‌های همه‌منظوره و ۱٬۰۰۰ برابرِ اضافی به‌دلیلِ سخت‌افزارِ تخصصیِ یادگیریِ ماشینی بوده. وب به‌عنوانِ منبعِ غنیِ تصاویر، ویدئو، گفتار، متن و دادهٔ نیمه‌ساخت‌یافته خدمت کرده، که در حالِ حاضر روزانه بیش از 10^{1}[8] بایت اضافه می‌کند.

صدها مجموعهٔ دادهٔ باکیفیت برای دامنه‌ای از تکلیف‌ها در بینایيِ رایانه، بازشناسیِ گفتار و پردازشِ زبانِ طبیعی در دسترس است. اگر دادهٔ موردنیاز از قبل موجود نباشد، اغلب می‌توانید آن را از منابعِ دیگر جمع کنید، یا از طریقِ پلتفرمِ جمع‌سپاری انسان‌هایی را برای برچسب‌زدنِ داده برایتان استخدام کنید. اعتبارسنجیِ دادهٔ به‌دست‌آمده به این‌شیوه بخشِ مهمی از جریانِ کارِ کلی می‌شود (هیرث و همکاران، 2013).

توسعهٔ مهمِ اخیر تغییر از دادهٔ مشترک به «مدلِ مشترک» (Shared Model) است. ارائه‌دهندگانِ عمدهٔ خدماتِ ابری (مثلاً، آمازون، مایکروسافت، گوگل، علی‌بابا، IBM، سیلزفورس) شروع به رقابت در ارائهٔ APIهای یادگیریِ ماشینی با مدل‌های ازپیش‌ساخته

برای تکلیف‌های خاص مانندِ بازشناسیِ اشیای بصری، بازشناسیِ گفتار و ترجمهٔ ماشینی کرده‌اند. این مدل‌ها را می‌توان همان‌گونه استفاده کرد، یا می‌توانند به‌عنوانِ خطِّ پایه‌ای برای سفارشی‌سازی با دادهٔ خاصِ شما برای کاربردِ خاصِ شما خدمت کنند. انتظار داریم این مدل‌ها در طولِ زمان بهبود یابند، و غیرعادی شود پروژهٔ یادگیریِ ماشینی را از صفر شروع کنیم، درست همان‌گونه که اکنون غیرعادی است پروژهٔ توسعهٔ وب را بدونِ کتابخانه از صفر انجام دهیم. ممکن است جهشِ بزرگی در کیفیتِ مدل رخ دهد وقتی پردازشِ همهٔ ویدئویِ وب اقتصادی شود؛ برای نمونه، پلتفرمِ یوتیوب به‌تنهایی هر دقیقه ۳۰۰ ساعت ویدئو اضافه می‌کند.

قانونِ مور پردازشِ داده را مقرون‌به‌صرفه‌تر کرده؛ یک مگابایت ذخیره در 1969 یک میلیون دلار و در 2019 کمتر از ۰٫۰۲ دلار هزینه داشت، و توانِ گذردهیِ ابررایانه در آن زمان با ضریبِ بیش از 10^{1}° افزایش یافته. اجزای سخت‌افزاریِ تخصصی برای یادگیریِ ماشینی مانندِ واحدهای پردازشِ گرافیکی (GPU)، هسته‌های تانسوری، واحدهای پردازشِ تانسوری (TPU) و آرایه‌های گیتِ برنامه‌پذیرِ میدانی (FPGA) برای آموزشِ یادگیریِ ماشینی صدها بار سریع‌تر از CPUهای معمولی‌اند (واسیلاچه و همکاران، 2014؛ جوپی و همکاران، 2017). در 2014 یک روز کامل طول می‌کشید تا مدلِ ImageNet آموزش ببیند؛ در 2018 فقط ۲ دقیقه (بینگ و همکاران، 2018).

مؤسسهٔ OpenAI گزارش می‌دهد مقدارِ قدرتِ محاسباتیِ استفاده‌شده برای آموزشِ بزرگ‌ترین مدل‌های یادگیریِ ماشینی از 2012 تا 2018 هر ۳٫۵ ماه دو برابر شد، و برای آلفازیرو به بیش از یک اگزافلاپ/ثانیه-روز رسید (هرچند آن‌ها همچنین گزارش می‌کنند برخی کارهای بسیار تأثیرگذار از ۱۰۰ میلیون بار قدرتِ محاسباتیِ کمتری استفاده کردند (آمودی و هرناندز، 2018)). همان روندهای اقتصادی که دوربین‌های گوشیِ همراه را ارزان‌تر و بهتر کرده‌اند برای پردازنده‌ها نیز برقرارند—پیشرفتِ ادامه‌دار در محاسباتِ کم‌مصرف و پرقدرت خواهیم دید که از صرفه‌های مقیاس بهره می‌برد.

این امکان هست رایانه‌های کوانتومی هوش مصنوعی را شتاب دهند. در حالِ حاضر برخی الگوریتم‌های کوانتومیِ سریع برای عملیاتِ جبرِ خطیِ استفاده‌شده در یادگیریِ ماشینی هست (هارو و همکاران، 2009؛ دروویچ و همکاران، 2018)، اما هیچ رایانهٔ کوانتومیِ قادر به اجرایِ آن‌ها نیست. نمونه‌هایی از کاربردهای تکلیف‌هایی مانندِ رده‌بندیِ

تصویر (موت و همکاران، 2017) داریم که الگوریتم‌های کوانتومی در مسائلِ کوچک به همان خوبیِ الگوریتم‌های کلاسیک‌اند. رایانه‌های کوانتومیِ کنونی فقط چند ده بیت مدیریت می‌کنند، در حالی که الگوریتم‌های یادگیریِ ماشینی اغلب ورودی‌هایی با میلیون‌ها بیت مدیریت و مدل‌هایی با صدها میلیون پارامتر ایجاد می‌کنند. پس برای عملی‌کردنِ محاسباتِ کوانتومی برای یادگیریِ ماشینیِ مقیاس‌بزرگ به پیشرفت‌هایی در هر دوِ سخت‌افزار و نرم‌افزارِ کوانتومی نیاز داریم. یا، ممکن است تقسیمِ کاری باشد—شاید الگوریتمِ کوانتومی برای جستجویِ کارآمدِ فضایِ ابرپارامترها در حالی که فرایندِ آموزشِ معمولی رویِ رایانه‌های معمولی اجرا می‌شود—اما هنوز نمی‌دانیم چگونه آن را انجام دهیم. پژوهشِ الگوریتم‌های کوانتومی گاهی می‌تواند الگوریتم‌های تازه و بهتری را رویِ رایانه‌های کلاسیک الهام کند (تانگ، 2018).

همچنین رشدِ نمایی در تعدادِ انتشارات، افراد و دلارها در هوش مصنوعی/یادگیریِ ماشینی/علمِ داده دیده‌ایم. دین و همکاران (2018) نشان می‌دهند تعدادِ مقاله‌های «یادگیریِ ماشینی» رویِ arXiv از 2009 تا 2017 هر دو سال دو برابر شد. سرمایه‌گذاران در حالِ تأمین‌مالیِ شرکت‌های استارتاپی در این حوزه‌ها هستند، شرکت‌های بزرگ در حالِ استخدام و هزینه‌کردن‌اند، و دولت‌ها سرمایه‌گذاری می‌کنند تا مطمئن شوند کشورشان...

۲۸.۲ معماری‌های هوش مصنوعی

پرسیدنِ اینکه «کدام یک از معماری‌های عاملِ فصل ۲ را یک عامل باید استفاده کند؟» طبیعی است. پاسخ این است: «همهٔ آن‌ها!» پاسخ‌های بازتابی برای موقعیت‌هایی لازم‌اند که زمان در آن‌ها حیاتی است، در حالی که تعمقِ دانش‌محور به عامل اجازه می‌دهد از پیش برنامه‌ریزی کند. یادگیری وقتی دادهٔ زیادی داریم راحت است، و وقتی محیط در حالِ تغییر است، یا طراحانِ انسانی دانشِ کافی از حوزه ندارند، ضروری است.

هوش مصنوعی مدتِ طولانی است بینِ سامانه‌های نمادین (مبتنی بر استنتاجِ منطقی و احتمالاتی) و سامانه‌های پیوندگرا (مبتنی بر کمینه‌سازیِ زیان رویِ تعدادِ زیادی پارامترِ تفسیرنشده) شکاف داشته. چالشِ ادامه‌دارِ هوش مصنوعی گردآوردنِ این دو، برای

دربرگرفتنِ بهترین هر دو، است. سامانه‌های نمادین به ما اجازه می‌دهند زنجیره‌های بلندی از استدلال به هم بندیم و از قدرتِ بیانیِ بازنمایی‌های ساخت‌یافته بهره بگیریم، در حالی که سامانه‌های پیوندگرا می‌توانند الگوها را حتی در مواجهه با دادهٔ نویزی بازشناسی کنند. یکی از خطوطِ پژوهش هدفش ترکیبِ برنامه‌نویسیِ احتمالاتی با یادگیری عمیق است، هرچند تاکنون پیشنهادهای گوناگون در میزانی که رویکردها واقعاً ادغام می‌شوند محدودند.

عامل‌ها همچنین به راه‌هایی برای کنترلِ تعمق‌های خودشان نیاز دارند. باید بتوانند از زمانِ در دسترس خوب استفاده کنند، و وقتی کنش طلبیده می‌شود تعمق را متوقف کنند. برای نمونه، عاملِ رانندهٔ تاکسی که تصادفی را پیشِ رو می‌بیند باید در کسری از ثانیه تصمیم بگیرد ترمز کند یا منحرف شود. همچنین باید آن کسرِ ثانیه را صرفِ فکرکردن به مهم‌ترین پرسش‌ها کند، مانندِ اینکه آیا خطوطِ چپ و راست بازند و آیا کامیونِ بزرگی نزدیکِ پشتِ سر هست، نه نگرانی دربارهٔ اینکه مسافرِ بعدی را کجا سوار کند. این مسائل معمولاً تحتِ عنوانِ «هوش مصنوعیِ زمان-واقعی» (Real-Time AI) مطالعه می‌شوند. با حرکتِ سامانه‌های هوش مصنوعی به حوزه‌های پیچیده‌تر، همهٔ مسائل زمان-واقعی خواهند شد، زیرا عامل هرگز زمانِ کافی برای حلِ دقیقِ مسئلهٔ تصمیم نخواهد داشت.

واضح است، نیازِ فوری به روش‌های عمومیِ کنترلِ تعمق هست، نه دستورهای خاصِ اینکه در هر موقعیت به چه فکر کنیم. نخستین ایدهٔ مفید «الگوریتم‌های همیشگی» (Anytime Algorithm) است (دین و بادی، 1988؛ هورویتز، 1987): الگوریتمی که کیفیتِ خروجی‌اش به‌تدریج در طولِ زمان بهبود می‌یابد، تا هر وقت قطع شود تصمیمِ معقولی آماده داشته باشد. نمونه‌های الگوریتم‌های همیشگی شاملِ تعمیقِ تکراری در جستجویِ درختِ بازی و MCMC در شبکه‌های بیزی است. فنِ دوم برای کنترلِ تعمق «فراستدلالِ تصمیم-نظری» (Decision-Theoretic Metareasoning) است (راسل و وفالد، 1989؛ هورویتز و بریس، 1996؛ هی و همکاران، 2012). این روش، که در بخش‌های ۳.۶.۵ و ۵.۷ به‌طورِ مختصر ذکر شد، نظریهٔ ارزشِ اطلاعات (فصل ۱۶) را بر انتخابِ محاسباتِ منفرد اعمال می‌کند. ارزشِ یک محاسبه هم به هزینه‌اش (از نظرِ به‌تأخیرانداختنِ کنش) و هم به مزیت‌هایش (از نظرِ کیفیتِ بهبودیافتهٔ

تصمیم) بستگی دارد. فنونِ فراستدلال را می‌توان برای طراحیِ الگوریتم‌های جستجویِ بهتر و برای تضمینِ اینکه الگوریتم‌ها ویژگیِ همیشگی دارند استفاده کرد. جستجویِ درختِ مونت‌کارلو یک نمونه است: انتخابِ گرهٔ برگ که پخشِ بعدی از آن آغاز می‌شود توسط تصمیمِ فراسطحیِ تقریباً عقلاییِ برگرفته از نظریهٔ باندیت انجام می‌شود.

فراستدلال گران‌تر از کنشِ بازتابی است، البته، اما می‌توان روش‌های کامپایل را اعمال کرد تا سربار در مقایسه با هزینه‌های محاسباتِ در حالِ کنترل کوچک باشد. یادگیریِ تقویتیِ فراسطحی ممکن است راهِ دیگری برای کسبِ سیاست‌های مؤثرِ کنترلِ تعمق فراهم کند: در اصل، محاسباتی که به تصمیم‌های بهتر می‌انجامند تقویت می‌شوند، در حالی که آن‌هایی که معلوم می‌شود بی‌اثرند جریمه می‌شوند. این رویکرد از مشکلاتِ کوته‌بینیِ محاسبهٔ سادهٔ ارزشِ اطلاعات اجتناب می‌کند.

فراستدلال یکی از نمونه‌های خاصِ معماریِ بازتابی است—یعنی معماری‌ای که تعمق دربارهٔ موجودیت‌ها و کنش‌های محاسباتیِ رخ‌داده در درونِ خودِ معماری را ممکن می‌کند. بنیانِ نظریِ معماری‌های بازتابی را می‌توان با تعریفِ فضایِ حالتِ مشترکی که از حالتِ محیط و حالتِ محاسباتیِ خودِ عامل ساخته شده بنا کرد. الگوریتم‌های تصمیم‌گیری و یادگیری را می‌توان طراحی کرد که رویِ این فضایِ حالتِ مشترک عمل کنند و بدین‌ترتیب فعالیت‌های محاسباتیِ عامل را پیاده‌سازی و بهبود بخشند. در نهایت، انتظار داریم الگوریتم‌های خاصِ تکلیف مانندِ جستجویِ آلفا-بتا، برنامه‌ریزیِ رگرسیونی و حذفِ متغیر از سامانه‌های هوش مصنوعی ناپدید شوند، و با روش‌های عمومی‌ای جایگزین شوند که محاسباتِ عامل را به سمتِ تولیدِ کارآمدِ تصمیم‌های باکیفیت هدایت می‌کنند.

فراستدلال و بازتاب (و بسیاری از ابزارهای معماری و الگوریتمیِ مرتبط با کارایی که در این کتاب کاوش شده‌اند) لازم‌اند، زیرا تصمیم‌گیری سخت است. از وقتی رایانه‌ها اختراع شدند، سرعتِ خیره‌کننده‌شان مردم را به بیش‌برآوردِ تواناییشان در غلبه بر پیچیدگی، یا به‌طورِ هم‌ارز، کم‌برآوردِ اینکه پیچیدگی واقعاً چه معنایی دارد، کشانده.

قدرتِ واقعاً غول‌پیکرِ ماشین‌های امروز آدم را وسوسه می‌کند فکر کند می‌توانیم از همهٔ ابزارهای هوشمندانه دور بزنیم و بیشتر بر نیرویِ خام تکیه کنیم. پس بیایید بکوشیم با این گرایش مقابله کنیم. با آنچه فیزیکدانان باور دارند سرعتِ دستگاهِ محاسباتیِ نهاییِ ۱ کیلوگرمی است شروع می‌کنیم:

حدودِ 10^{5}[1] عملیات در ثانیه، یا یک میلیارد تریلیون تریلیون بار سریع‌تر از سریع‌ترین ابررایانهٔ تا 2020 (لوید، 2000). سپس تکلیفِ ساده‌ای پیشنهاد می‌کنیم: برشمردنِ رشته‌های واژه‌های انگلیسی، همان‌گونه که بورخس در «کتابخانهٔ بابل» پیشنهاد کرد. بورخس کتاب‌هایی با ۴۱۰ صفحه تصریح کرد. آیا آن شدنی می‌بود؟ نه کاملاً. در واقع، رایانه‌ای که یک سال اجرا شود فقط می‌توانست رشته‌های ۱۱-واژه‌ای را برشمارد.

حالا این واقعیت را در نظر بگیر که برنامهٔ مفصلی برای زندگیِ انسانی شاملِ (تقریباً) بیست تریلیون فعال‌سازیِ ماهیچه‌ایِ بالقوه است (راسل، 2019)، و شروع به دیدنِ مقیاسِ مسئله می‌کنی. رایانه‌ای که یک میلیارد تریلیون تریلیون بار قدرتمندتر از مغزِ انسان است از عقلایی‌بودن بسیار دورتر است تا لخت‌پوستی از سبقت‌گرفتن از سفینهٔ فضاییِ انترپرایزِ در حالِ حرکت با وارپِ نه.

با این ملاحظات در ذهن، به نظر می‌رسد هدفِ ساختنِ عاملِ عقلایی شاید کمی بیش‌ازحد جاه‌طلبانه است. به‌جای هدف‌گرفتنِ چیزی که نمی‌تواند وجود داشته باشد، باید هدفِ هنجاریِ متفاوتی را در نظر بگیریم—هدفی که لزوماً وجود دارد. از فصل ۲ ایدهٔ سادهٔ زیر را به یاد آور:

> **عامل = معماری + برنامه**

حالا معماریِ عامل (قابلیت‌های ماشینِ زیرین، شاید با لایهٔ نرم‌افزاریِ ثابتی رویِ آن) را ثابت کن و به برنامهٔ عامل اجازه بده رویِ همهٔ برنامه‌های ممکنی که معماری می‌تواند پشتیبانی کند تغییر کند. در هر محیطِ تکلیفیِ داده‌شده، یکی از این برنامه‌ها (یا ردهٔ هم‌ارزی از آن‌ها) بهترین عملکردِ ممکن را تحویل می‌دهد—شاید نزدیکِ عقلانیتِ کامل

نباشد، اما همچنان بهتر از هر برنامهٔ عاملِ دیگر. می‌گوییم این برنامه معیارِ «بهینگیِ کران‌دار» (Bounded Optimality) را برآورده می‌کند. واضح است وجود دارد، و واضح است هدفِ مطلوبی را تشکیل می‌دهد. ترفند یافتنِ آن، یا چیزی نزدیکِ آن، است.

برای برخی رده‌های مقدماتیِ برنامه‌های عامل در محیط‌های سادهٔ زمان-واقعی، شناساییِ برنامه‌های عاملِ بهینهٔ کران‌دار ممکن است (اتزیونی، 1989؛ راسل و سوبرامانیان، 1995). موفقیتِ جستجویِ درختِ مونت‌کارلو علاقه به تصمیم‌گیریِ فراسطحی را زنده کرده، و دلیلی برای امیدواری هست که بهینگیِ کران‌دار درونِ خانواده‌های پیچیده‌ترِ برنامه‌های عامل با فنونی مانندِ یادگیریِ تقویتیِ فراسطحی محقق شود. همچنین باید بتوان نظریهٔ سازنده‌ای از معماری توسعه داد، که با قضیه‌هایی دربارهٔ بهینگیِ کران‌دارِ روش‌های مناسبِ ترکیبِ مؤلفه‌های بهینهٔ کران‌دارِ متفاوت مانندِ سامانه‌های بازتابی و کنش-ارزش آغاز می‌شود.

هوش مصنوعیِ عمومی

بخشِ زیادی از پیشرفتِ هوش مصنوعی در قرنِ بیست‌ویکم تاکنون توسط رقابت رویِ تکلیف‌های باریک هدایت شده، مانندِ چالشِ بزرگِ DARPA برای خودروهای خودمختار، رقابتِ بازشناسیِ اشیای ImageNet، یا بازیِ گو، شطرنج، پوکر یا Jeopardy! در برابرِ قهرمانِ جهان. برای هر تکلیفِ جداگانه، سامانهٔ هوش مصنوعیِ جداگانه‌ای می‌سازیم، معمولاً با مدلِ یادگیریِ ماشینیِ جداگانه‌ای که از صفر با داده‌ای که مخصوصِ این تکلیف جمع‌آوری شده آموزش می‌بیند. اما عاملِ واقعاً هوشمند باید بتواند بیش از یک کار انجام دهد. آلن تورینگ (1950) فهرستش را پیشنهاد کرد (صفحهٔ ۹۸۲) و نویسندهٔ علمی-تخیلیِ رابرت هاینلاین (1973) مقابله کرد:[1]

> انسان باید بتواند پوشک عوض کند، حمله برنامه‌ریزی کند، خوک سلاخی کند، کشتی را هدایت کند، ساختمان طراحی کند، غزل بنویسد، حساب‌ها را تراز کند، دیوار بسازد، استخوان جا بیندازد، داغدیدگان را دلداری دهد، فرمان بگیرد، فرمان دهد، همکاری کند، تنها عمل کند، معادله حل کند، مسئلهٔ تازه تحلیل کند، کود بریزد، رایانه برنامه‌نویسی کند، غذای خوشمزه بپزد، کارآمد بجنگد، شجاعانه بمیرد. تخصص‌گرایی برای حشرات است.
>
> **— رابرت هاین‌لاین (1973)**

تاکنون، هیچ سامانهٔ هوش مصنوعی‌ای به هیچ‌کدام از این دو فهرست نمی‌رسد، و برخی طرفدارانِ هوش مصنوعیِ عمومی یا سطح-انسان (HLAI) اصرار می‌ورزند کارِ ادامه‌دار رویِ تکلیف‌های خاص (یا رویِ مؤلفه‌های منفرد) برای رسیدن به تسلط رویِ طیفِ وسیعی از تکلیف‌ها کافی نخواهد بود؛ به رویکردِ بنیاداً تازه‌ای نیاز خواهیم داشت. به نظر ما پیشرفت‌های تازهٔ متعددی در واقع لازم خواهد بود، اما در مجموع، هوش مصنوعی به‌عنوانِ حوزه مبادلهٔ کاوش/بهره‌برداریِ معقولی کرده، سبدی از مؤلفه‌ها گرد آورده، تکلیف‌های خاص را بهبود بخشیده، و در عین حال ایده‌های تازهٔ امیدوارکننده و گاهی دور از دسترس را کاوش کرده.

اشتباه می‌بود در 1903 به برادرانِ رایت گفتنِ اینکه کار رویِ هواپیمایِ تک‌تکلیفی‌شان را متوقف کنند و «ماشینِ پروازِ مصنوعیِ عمومی»ای طراحی کنند که می‌تواند عمودی بلند شود، سریع‌تر از صدا پرواز کند، صدها مسافر حمل کند و رویِ ماه فرود آید. همچنین اشتباه می‌بود دنبالِ نخستین پروازشان با رقابتِ سالانه‌ای برای بهترکردنِ تدریجیِ هواپیماهای دوبالهٔ چوبِ صنوبر می‌رفتیم.

دیده‌ایم کار رویِ مؤلفه‌ها می‌تواند ایده‌های تازه برانگیزد؛ برای نمونه، شبکه‌های مولدِ تخاصمی (GAN) و مدل‌های زبانِ ترنسفورمر هر یک حوزه‌های پژوهشیِ تازه‌ای گشودند. همچنین گام‌هایی به سمتِ «تنوعِ رفتار» دیده‌ایم. برای نمونه، سامانه‌های ترجمهٔ ماشینی در دههٔ ۱۹۹۰ یکی‌یکی برای هر جفت‌زبان (مانندِ فرانسوی به انگلیسی) ساخته می‌شدند،

اما امروزه سامانهٔ تکی می‌تواند متنِ ورودی را به‌عنوانِ یکی از صد زبان شناسایی و به هر یک از ۱۰۰ زبانِ مقصد ترجمه کند. سامانهٔ زبانِ طبیعیِ دیگری می‌تواند پنج تکلیفِ متمایز را با یک مدلِ مشترک انجام دهد (هاشیموتو و همکاران، 2016).

مهندسیِ هوش مصنوعی

حوزهٔ برنامه‌نویسیِ رایانه با چند پیشگامِ خارق‌العاده شروع شد. اما تا وقتی رویه‌ای از مهندسیِ نرم‌افزار توسعه نیافته بود، با مجموعه‌ای قدرتمند از ابزارهای گسترده‌در دسترس و اکوسیستمِ شکوفایی از معلمان، دانشجویان، دست‌اندرکاران، کارآفرینان، سرمایه‌گذاران و مشتریان، به جایگاهِ صنعتِ بزرگی نرسید.

صنعتِ هوش مصنوعی هنوز به آن سطحِ بلوغ نرسیده. انواعِ گوناگونی از ابزارها و چارچوب‌های قدرتمند داریم، مانندِ TensorFlow، Keras، PyTorch، CAFFE، Scikit-Learn و SCIPY. اما بسیاری از امیدوارکننده‌ترین رویکردها، مانندِ GANها و یادگیریِ تقویتیِ عمیق، کارکردن با آن‌ها دشوار ثابت شده—به تجربه و درجه‌ای وررفتن نیاز دارند تا در حوزهٔ تازه‌ای درست آموزش ببینند. به‌اندازهٔ کافی کارشناس نداریم که این را در همهٔ حوزه‌هایی که نیاز داریم انجام دهیم، و هنوز ابزارها و اکوسیستمِ لازم برای موفقیتِ دست‌اندرکارانِ کم‌تجربه‌تر را نداریم.

جف دینِ گوگل آینده‌ای می‌بیند که در آن می‌خواهیم یادگیریِ ماشینی میلیون‌ها تکلیف را مدیریت کند؛ توسعهٔ هر یک از صفر شدنی نخواهد بود، پس پیشنهاد می‌کند به‌جای ساختنِ هر سامانهٔ تازه از صفر، با یک سامانهٔ عظیمِ تکی شروع کنیم و برای هر تکلیفِ تازه، بخش‌های مربوط به تکلیف را از آن استخراج کنیم. گام‌هایی در این جهت دیده‌ایم، مانندِ مدل‌های زبانِ ترنسفورمر (مثلاً، BERT، GPT-2) با میلیاردها پارامتر، و معماریِ شبکهٔ عصبیِ گروهیِ «به‌شکلِ توهین‌آمیزی بزرگ» که در یک آزمایش تا ۶۸ میلیارد پارامتر مقیاس می‌شود (شازیر و همکاران، 2017). کارِ بسیار باقی مانده.

آینده

آینده به کدام سمت خواهد رفت؟ نویسندگانِ علمی-تخیلی به نظر می‌رسد آینده‌های ویران‌شهری را بر مدینه‌های فاضله ترجیح می‌دهند، احتمالاً چون داستان‌های جالب‌تری می‌سازند. تاکنون، هوش مصنوعی به نظر می‌رسد با دیگر فناوری‌های انقلابیِ قدرتمند مانندِ چاپ، لوله‌کشی، سفرِ هوایی و تلفن جور در می‌آید. همهٔ این فناوری‌ها اثرهای مثبتی داشته‌اند، اما همچنین برخی اثرهای جانبیِ ناخواسته دارند که به‌صورتِ نامتناسب بر طبقاتِ محروم اثر می‌گذارد. خوب است در سرمایه‌گذاری برای کمینه‌کردنِ اثرهای منفی سرمایه‌گذاری کنیم.

هوش مصنوعی همچنین با فناوری‌های انقلابیِ قبلی متفاوت است. بهبودِ چاپ، لوله‌کشی، سفرِ هوایی و تلفن تا حدِّ منطقی‌شان هیچ‌چیزِ تهدیدکنندهٔ برتریِ انسانی در جهان تولید نمی‌کرد. بهبودِ هوش مصنوعی تا حدِّ منطقی‌اش قطعاً می‌توانست.

در پایان، هوش مصنوعی در تاریخچهٔ کوتاهش پیشرفتِ بزرگی کرده، اما جملهٔ پایانیِ مقالهٔ آلن تورینگ (1950) دربارهٔ «ماشین‌های محاسبه و هوش» همچنان امروز معتبر است:

> «ما فقط می‌توانیم فاصله‌ای کوتاه به جلو را ببینیم، اما می‌بینیم که کارِ بسیار باقی مانده است.»
> **— آلن تورینگ (1950)**

پانوشت‌ها:

[1] از این واقعیت چشم‌پوشی می‌کنیم که این دستگاه کلِ خروجیِ انرژیِ یک ستاره را مصرف می‌کند و در یک میلیارد درجهٔ سانتی‌گراد کار می‌کند.